

Estimation ponctuelle & distribution d'échantillonnage


1 Introduction :

1.1 Généralités sur la notion d'échantillonnage :

En statistique, les chercheurs veulent pouvoir tirer des conclusions au sujet d'une population qui présente les caractéristiques communes qui les intéressent : **la population cible**.

La plupart des populations étant trop grandes pour qu'on les étudie en entier à cause de **contraintes temporelles, financières et logistiques**, les chercheurs effectuent souvent leurs études sur **des échantillons** qu'ils croient représentatifs de la population cible.

Un échantillon représentatif, sous-ensemble de la population étudiée, a les mêmes caractéristiques que la population dont il est tiré :



Pour obtenir un échantillon représentatif, les chercheurs effectuent deux types d'échantillonnage :

1-Echantillonnage sur la base des méthodes empiriques : La méthode des quotas (se base sur la composition de la population pour certains critères) est la plus utilisée.


2-Echantillonnage aléatoire simple : Tous les échantillons possibles de même taille ont la même probabilité d'être choisis et tous les éléments de la population ont une chance égale de faire partie de l'échantillon.

Dans ce cours, on considère le cas le plus simple, l'échantillonnage aléatoire simple, qui consiste à tirer de façon équiprobable n individus à partir de la population.

Maintenant, à partir de ce nombre fini des variables aléatoires (échantillon), on veut connaître le paramètre θ de la population, qui donne la loi d'une seule variable aléatoire, (auparavant dans les chapitres précédents, le paramètre θ est supposé connu, et par la suite la loi de la variable aléatoire est connue).

⇒ Il faut suivre une démarche statistique pour connaître l'inconnu θ .

Une **démarche statistique** consiste à utiliser l'information obtenue sur un échantillon (un nombre fini des variables aléatoires) pour pouvoir déduire de l'information sur la population ou l'univers (un nombre infini des variables aléatoires) : on **extraît** un échantillon de la population, on l'analyse et on **infère** sur la population.



Qu'ils traitent un échantillon ou une population, les statisticiens décrivent habituellement ces ensembles à l'aide de mesures telles que le nombre d'unité, la moyenne, l'écart-type et le pourcentage.

- Les mesures qu'on utilise pour décrire une population sont **des paramètres**.

Un paramètre est une caractéristique de la population.

- Les mesures qu'on utilise pour décrire un échantillon sont appelées **des statistiques**.

Une statistique est une caractéristique de l'échantillon.

1.2 Notion d'estimation paramétrique :

Activité introductive :

”Comment on peut vérifier expérimentalement qu’une pièce de monnaie est équilibrée ?”

On jette cette pièce de monnaie n —fois et on associe pour chaque lancée une variable aléatoire $X \sim \mathcal{B}(p)$ Bernoulli de paramètre $p \in]0, 1[$.

La $i^{\text{ème}}$ lancée correspond à la variable aléatoire X_i définie comme suit :

$$X_i \sim \mathcal{B}(p) \implies \left\{ \begin{array}{l} \omega_1 = P \\ \omega_2 = F \end{array} \right\} \xrightarrow{X_i} \left\{ \begin{array}{l} 1 \\ 0 \end{array} \right\} \quad \forall 1 \leq i \leq n$$

Alors les X_i sont indépendantes et de même loi que $X \sim \mathcal{B}(p)$. C’est ainsi, afin de vérifier si cette pièce de monnaie est équilibrée ou non, il suffit de vérifier si $p = \frac{1}{2}$ ou non. Comme l’inconnu p est l’espérance de la loi de Bernoulli, $X \sim \mathcal{B}(p)$

$$\mathbb{E}[X] = p$$

L’idée ici est de l’estimer ou de l’approcher par la variable aléatoire suivante :

$$\frac{S_n}{n} = \frac{X_1(\omega) + X_2(\omega) + \cdots + X_n(\omega)}{n}$$

Contexte général :

Estimer un paramètre consiste à chercher une valeur approchée en se basant sur les résultats obtenus à partir d’un échantillon aléatoire.

Pour cela dans ce cours, on s’intéresse à estimer certaines caractéristiques statistiques (moyenne, variance, proportion) d’une certaine loi par différentes méthodes, où cette loi théorique on la connaît mais on ignore son paramètre. $\implies$ C’est le cadre d’une **estimation paramétrique unidimensionnelle**.

On cite deux types d’estimations paramétriques :

Estimation paramétrique ponctuelle : l’estimation est donnée par une seule valeur.

(E.M.M) La méthode des moments

(E.M.V) La méthode du maximum de vraisemblance

Estimation paramétrique par intervalle de confiance :

— Intervalle centré

— Intervalle décentré

2 Estimation paramétrique ponctuelle

Lorsqu'un paramètre est estimé par un seul nombre, déduit des résultats de l'échantillon, ce nombre est appelé **estimation ponctuelle** du paramètre.

Définition 1

Un échantillon de taille n (ou n -échantillon) est une famille $(X_1, \dots, X_n)$ de variables aléatoires indépendantes et identiquement distribuées (i.i.d) de même loi $\mathbb{P}_\theta$.

Une réalisation de taille n (ou n -réalisation) d'un n -échantillon est le résultat de n tirages indépendants selon la loi de X_i , c'est une collection $(x_1, \dots, x_n)$ de points de $\mathbb{R}$.

Définition 2

Soit $(X_1, \dots, X_n)$ un n -échantillon, de loi $\mathbb{P}_\theta$, $\theta \in \mathbb{R}$, $(x_1, \dots, x_n)$ une n -réalisation, et $g : \mathbb{R}^n \rightarrow \mathbb{R}$ une fonction continue.

On appelle :

- **Une statistique** est toute fonction $g(X_1, \dots, X_n)$ de l'échantillon.
- **Un estimateur** de θ toute statistique utilisée pour estimer θ .
- **Une estimation** de θ toute fonction $g(x_1, \dots, x_n)$ de la réalisation.

$\implies$ Évidemment un estimateur $\hat{\theta}_n$ de θ est une statistique permettant d'évaluer le paramètre inconnu θ relatif à la loi de probabilité parente $\mathbb{P}_\theta$.

Exemple 1 Soit $(X_1, \dots, X_n)$ un n -échantillon de loi de Bernoulli $\mathcal{B}(p)$ et $(0, 1, 1, 0, \dots, 1)$ une n -réalisation alors :

$$\hat{p}_n = \frac{X_1 + \dots + X_n}{n} \quad \text{un estimateur de } p$$

$$\tilde{p}_n = \frac{0 + 1 + 1 + 0 + \dots + 1}{n} \quad \text{une estimation de } p$$

2.1 Propriétés des estimateurs ponctuels

Un paramètre inconnu θ peut avoir plusieurs estimateurs, par exemple pour estimer le paramètre m moyenne d'une population, on pourrait se servir de la moyenne arithmétique, de

la médiane ou du mode. C'est pourquoi on doit choisir le meilleur estimateur de θ parmi tous ses estimateurs, autrement dit on doit choisir celui qui s'approche le plus possible de θ . Divers propriétés peuvent être citées et elles servent à mesurer la qualité de l'estimateur choisi.

2.1.1 Estimateur sans biais

Définition 3

Soit $\hat{\theta}_n$ un estimateur de $\theta \in \mathbb{R}$ telque $\mathbb{E}(\hat{\theta}_n) < \infty$.

On appelle **biais** de $\hat{\theta}_n$ par rapport à θ le réel défini par :

$$\mathbb{E}(\hat{\theta}_n - \theta) = \mathbb{E}(\hat{\theta}_n) - \theta.$$

On dit que $\hat{\theta}_n$ est un estimateur **sans biais** (ou bien **non biaisé**) de θ si

$$\mathbb{E}(\hat{\theta}_n) = \theta$$

sinon, on dit qu'il est **avec biais** (ou bien **biaisé**).

Exemple 2 (moyenne empirique) Soit $(X_1, \dots, X_n)$ un n -échantillon de loi $\mathcal{L}_\theta$, $\theta \in \mathbb{R}$, et $\mathbb{E}(X) < \infty$. En se basant sur l'exemple 1, nous déduisons que la variable aléatoire définie par :

$$\frac{S_n}{n} = \frac{X_1 + \dots + X_n}{n}$$

est un estimateur sans biais de $\mathbb{E}(X)$. Cette variable est dite **moyenne empirique** et elle est notée $\bar{X}_n$.

Exemple 3 (Variance empirique) Soit $(X_1, \dots, X_n)$ un n -échantillon aléatoire d'une population X de moyenne m et de variance σ^2 . Considérons la variable aléatoire suivante :

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2$$

Nous obtenons par la suite que :

$$\mathbb{E}(\hat{\sigma}^2) = \frac{n-1}{n} \sigma^2, \quad \text{avec } \sigma^2 : \text{ la valeur de la variance dans la population.}$$

Donc la variable aléatoire $\hat{\sigma}^2$ est dite **variance empirique** de l'échantillon, et clairement elle présente un estimateur biaisé du paramètre σ^2 . C'est pour cette raison qu'on va

considérer la statistique (v.a) suivante :

$$S^2 = \frac{n}{n-1} \hat{\sigma}^2$$

dite **variance empirique corrigée** de l'échantillon, qui est clairement un estimateur sans biais de σ^2 , puisque $\mathbb{E}(S^2) = \sigma^2$.

Notation : Dans le reste chapitre, on note par :

1. L'estimation de la variance σ^2 , définie par :

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x}_n)^2.$$

2. La variance empirique corrigée, l'estimateur de la variance par :

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2.$$

Remarque 1

Le biais mesure le décalage en moyenne entre les valeurs prises par l'estimateur et la vraie valeur du paramètre.

2.1.2 Estimateur asymptotiquement sans biais

Définition 4

Un estimateur $(\hat{\theta}_n)_{n \geq 1}$ de θ est appelé estimateur **asymptotiquement sans biais** de $\theta \in \mathbb{R}$ si :

$$\lim_{n \rightarrow +\infty} \mathbb{E}(\hat{\theta}_n - \theta) = \lim_{n \rightarrow +\infty} \left(\mathbb{E}(\hat{\theta}_n) - \theta \right) = 0$$

Remarque 2

L'absence de biais, toute seule, ne garantit pas que nous avons un bon estimateur, elle sera utile lorsqu'on veut démontrer l'optimalité de certains estimateurs dans une certaine classe ; dans la pratique, ce n'est pas une condition toujours désirable : il est tout à fait possible qu'un estimateur biaisé soit meilleur qu'un estimateur non biaisé. Le choix entre les estimateurs s'effectue en comparant ce qu'on appellera le **risque quadratique**.

2.1.3 Estimateur meilleur

Définition 5

Soit $\hat{\theta}_n$ un estimateur de $\theta \in \mathbb{R}$ admettant un moment d'ordre 2.

On appelle le **risque quadratique** de l'estimateur $\hat{\theta}_n$ la fonction $R_{\hat{\theta}_n}$ définie par :

$$R_{\hat{\theta}_n}(\theta) = \mathbb{E} \left((\hat{\theta}_n - \theta)^2 \right)$$

- Un estimateur $\hat{\theta}_n$ de θ est dit **meilleur** qu'un autre estimateur $\hat{T}_n$ de θ si et seulement si

$$R_{\hat{\theta}_n}(\theta) \leq R_{\hat{T}_n}(\theta).$$

Remarque 3

On peut exprimer le risque quadratique à l'aide de la variance par la formule suivante :

$$R_{\hat{\theta}_n}(\theta) = V(\hat{\theta}_n) + \left(\mathbb{E}_{\theta}(\hat{\theta}_n - \theta) \right)^2.$$

2.1.4 Estimateur de variance minimale

Définition 6

Un estimateur sans biais et admettant un moment d'ordre 2 est dit de **variance minimale** si sa variance est la plus faible parmi les variances des autres estimateurs sans biais.

Ainsi, si $\hat{\theta}_n$ et $\hat{T}_n$ sont deux estimateurs sans biais du paramètre θ , l'estimateur $\hat{\theta}_n$ est de variance minimale si et seulement si

$$\mathbb{V}(\hat{\theta}_n) < \mathbb{V}(\hat{T}_n) \text{ et } \mathbb{E}(\hat{\theta}_n) = \mathbb{E}(\hat{T}_n) = \theta$$

Exercice 1 Soit $(X_1, \dots, X_n)$ un n -échantillon d'une v.a. $X \sim \mathcal{U}([0, \theta])$, où θ est un paramètre strictement positif inconnu. Soit $\hat{\theta}_n = \max_{1 \leq i \leq n} X_i$ un estimateur de θ .

1. Montrer que $\mathbb{E}_\theta(\hat{\theta}_n) = \frac{n}{n+1}\theta$
2. Montrer que $\tilde{\theta}_n = 2\bar{X}_n$ est un estimateur sans biais de θ .
3. Montrer que $\hat{\theta}_n$ est meilleur que $\tilde{\theta}_n$.

2.1.5 Estimateur convergent

Définition 7

Soit $(\hat{\theta}_n)_{n \geq 1}$ une famille d'estimateurs de $\theta \in \mathbb{R}$ admettant un moment d'ordre 2, $(\hat{\theta}_n)_{n \geq 1}$ est dite **convergente** (dite aussi **consistante**) si et seulement si

$$\lim_{n \rightarrow +\infty} \mathbb{V}(\hat{\theta}_n) = 0$$

$\implies$ Si deux estimateurs sont convergents et sans biais, le meilleur est celui qui a **la variance la plus faible** car ses valeurs sont en moyenne plus proches de la quantité estimée.

2.2 Les méthodes d'estimation ponctuelle

2.2.1 Estimation par méthode des moments (E.M.M)

L'idée de base de cette méthode est d'utiliser les moments d'ordre 1 et 2 :

-Moment d'ordre 1 : pour estimer la moyenne $\mathbb{E}(X)$ par une moyenne empirique

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

-Moment non centré d'ordre 2 : pour estimer $\mathbb{E}(X^2)$ par

$$\overline{X_n^2} = \frac{1}{n} \sum_{k=1}^n X_k^2$$

-Moment centré d'ordre 2 : pour estimer la variance $\mathbb{V}(X)$ par une variance empirique

$$\overline{X_n^2} - (\overline{X_n})^2 = \frac{1}{n} \sum_{k=1}^n X_k^2 - (\overline{X_n})^2$$

- Pour $\theta \in \mathbb{R}$, si l'un des moments est une fonction de θ , par exemple $\mathbb{E}[X] = \varphi(\theta)$, où φ est une fonction bijective, alors l'estimateur de θ par la méthode des moments est $\hat{\theta}_n = \varphi^{-1}(\overline{X_n})$.

Exemple 4 Soit $(X_1, \dots, X_n)$ un n -échantillon qui suit la loi exponentielle de paramètre $\lambda > 0$. Déterminer l'estimateur de λ par la méthode des moments.

2.2.2 Estimation par la méthode du maximum de vraisemblance (E.M.V)

Soit $(X_1, \dots, X_n)$ un n -échantillon de loi $\mathcal{L}_\theta$ (discrète ou continue), avec $\theta \in \mathbb{R}$ un paramètre inconnu qu'on cherche à estimer. On vise maintenant à définir l'estimateur du maximum de vraisemblance de θ , pour cela on a besoin d'introduire la notion de la fonction de vraisemblance associée à un échantillon.

Définition 8

La fonction de vraisemblance de θ pour une réalisation $(x_1, \dots, x_n)$ d'un échantillon $(X_1, \dots, X_n)$ est l'application $L(x_1, \dots, x_n; \bullet) : \mathbb{R} \mapsto \mathbb{R}_+^*$ définie par, si X est :

Une variable aléatoire discrète : la loi de X est caractérisée par $\mathbb{P}_\theta$

$$L(x_1, \dots, x_n; \theta) = \prod_{i=1}^n \mathbb{P}_\theta(X_i = x_i),$$

Une variable aléatoire continue : la loi de X est caractérisée par f_θ

$$L(x_1, \dots, x_n; \theta) = \prod_{i=1}^n f_\theta(x_i),$$

Exemple 5 On considère un échantillon $\{X_1\}$ de taille $n = 1$. On suppose que $X_1 \sim \mathcal{B}(15, p)$, avec p inconnu. On observe $x_1 = 5$ et on cherche à estimer p .

1. Déterminer la fonction de vraisemblance $L(5; p)$.

2. Donner les valeurs particulières de L pour $p \in \{0.1; 0.2, 0.3, \dots, 0.9\}$.
3. Déterminer la valeur la plus vraisemblable de p .

La valeur la plus vraisemblable (probable) de p est celle pour laquelle la probabilité d'observer un 5 est maximale. C'est la valeur de p qui maximise la fonction de vraisemblance, ceci revient donc à chercher le maximum de la fonction de vraisemblance (dérivée première s'annule et dérivée seconde négative), mais comme la vraisemblance est un produit, alors il devient plus commode de maximiser une somme qu'un produit en passant à la fonction logarithme de la vraisemblance. De plus le fait que la valeur qui rend maximale une fonction rend aussi maximal son logarithme, nous permet de maximiser finalement le logarithme de la fonction de vraisemblance, qu'on appelle la **log-vraisemblance**.

Définition 9

Soit $L(x_1, \dots, x_n; \bullet)$ la fonction de vraisemblance associée à la réalisation $(x_1, \dots, x_n)$ de l'échantillon $(X_1, \dots, X_n)$ qui suit la loi $\mathbb{P}_\theta$.

On appelle estimateur du maximum de vraisemblance (E.M.V) de θ la variable aléatoire correspondante à la valeur $\hat{\theta}_n$ pour laquelle la fonction de vraisemblance atteint son maximum. Ce qui donne que $\hat{\theta}_n$ l'estimateur de maximum de vraisemblance de θ est solution du système :

$$\begin{cases} \frac{dL}{d\theta|_{\hat{\theta}_n}} = 0 \\ \frac{d^2L}{d\theta^2|_{\hat{\theta}_n}} < 0 \end{cases} \Leftrightarrow \begin{cases} \frac{d \ln L}{d\theta|_{\hat{\theta}_n}} = 0 \\ \frac{d^2 \ln L}{d\theta^2|_{\hat{\theta}_n}} < 0 \end{cases}$$

Exercice 2 Soit $(X_1, \dots, X_n)$ un n -échantillon qui suit la loi exponentielle de paramètre $\frac{1}{\theta}$ avec $\theta > 0$, i.e. la fonction densité de probabilité est donnée par :

$$f(x) = \begin{cases} \frac{1}{\theta} e^{-\frac{x}{\theta}} & \text{si } x \geq 0 \\ 0 & \text{sinon} \end{cases}$$

1. Donner la fonction de vraisemblance associée à une réalisation $(x_1, \dots, x_n)$ de l'échantillon.
2. Déterminer un estimateur $\hat{\theta}_n$ de θ par la méthode du maximum de vraisemblance.

3 Distribution d'échantillonnage

En statistique, on décrit un échantillon ou une population à l'aide des mesures ou caractéristiques telles que la moyenne, l'écart-type, le pourcentage. De ce fait, nous allons apprendre à estimer à l'aide d'un échantillon aléatoire simple **i.i.d** (c.à.d les variables aléatoires sont indépendantes et identiquement distribuées) :

- Caractère quantitatif** : on estimera la moyenne μ et l'écart type σ d'une population.
- Caractère qualitatif** : on estimera la proportion p de la population.

3.1 Distribution échantillonnale de la moyenne $\bar{X}_n$

Si nous prélevons un échantillon de taille k d'une population donnée, la moyenne de l'échantillon nous donnera une idée approximative sur la moyenne de la population. Seulement si nous prélevons un autre échantillon de même taille, nous obtiendrons une autre moyenne d'échantillon. Sur l'ensemble des échantillons possibles, on constatera que certains ont une moyenne proche de la moyenne de la population et que d'autres ont une moyenne qui s'en écarte davantage. Un échantillon de taille n (appelé aussi un n -échantillon), obtenu par échantillonnage aléatoire, va être considéré comme le résultat d'une expérience aléatoire. A chaque échantillon de taille k on peut associer la valeur moyenne des éléments de l'échantillon. On a donc défini une variable aléatoire qui à chaque n -échantillon associe sa moyenne échantillonnale. On la note $\bar{X}_n$.

On cherche à caractériser la variable aléatoire $\bar{X}_n$ par :

- Sa distribution de probabilité.
- Sa moyenne.
- Sa variance.

Définition 10

Soit $X_1, \dots, X_n$ une suite de variables aléatoires indépendantes et identiquement distribuées suivant X d'espérance m et d'écart-type σ . La moyenne empirique de n échantillons aléatoires est défini par :

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \quad \text{avec} \quad \mathbb{E}[\bar{X}_n] = m \quad \text{et} \quad \mathbb{V}[\bar{X}_n] = \frac{\sigma^2}{n}$$

Pour déterminer la distribution de probabilité de $\bar{X}_n$, nous allons distinguer deux cas : celui des grands échantillons ($n \geq 30$) et celui des petits échantillons ($n < 30$).

3.1.1 Cas des grands échantillons ($n \geq 30$)

Théorème 1 (Le théorème central limite(TCL))

Soit $X_1, \dots, X_n$ une suite de variables aléatoires indépendantes et identiquement distribuées suivant la loi de X d'espérance m et d'écart-type σ .

Alors, pour n est assez grand ($n \geq 30$), $Y = \sum_{i=1}^n X_i$ suit une loi normale de moyenne $n m$ et d'écart-type $\sqrt{n} \sigma$.

$$Y \sim \mathcal{N}(n m, \sqrt{n} \sigma)$$

En appliquant le théorème central limite, la loi normale est une bonne approximation de la loi de $\bar{X}_n$.

Proposition 1

Soit $X_1, \dots, X_n$ une suite de variables aléatoires indépendantes et identiquement distribuées suivant X d'espérance μ et d'écart-type σ . La moyenne empirique de n échantillons aléatoires est défini par :

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \quad \text{avec} \quad \mathbb{E}[\bar{X}_n] = m \quad \text{et} \quad \mathbb{V}[\bar{X}_n] = \frac{\sigma^2}{n}$$

De plus, quand n est assez grand ($n \geq 30$),

$$\bar{X}_n \sim \mathcal{N}(m, \frac{\sigma}{\sqrt{n}}) \quad \text{donc} \quad Z = \frac{\bar{X}_n - m}{\frac{\sigma}{\sqrt{n}}} \sim \mathcal{N}(0, 1)$$

Remarque 4

Si la variance σ^2 est inconnue, il suffit de l'estimer par

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x}_n)^2$$

On aura donc,

$$\bar{X}_n \sim \mathcal{N}(m, \frac{s}{\sqrt{n}}) \quad \text{donc} \quad Z = \frac{\bar{X}_n - m}{\frac{s}{\sqrt{n}}} \sim \mathcal{N}(0, 1)$$

Exemple 6 Soit un lot de 500 chocolats. Le poids d'un chocolat est une variable aléatoire d'espérance $m = 5g$ et de variance $\sigma^2 = 0.5g$. Quelle est la probabilité qu'une boîte de 50 chocolats issus de ce lot ait un poids moyen supérieur à $5.2g$?

3.1.2 Cas des petits échantillons ($n < 30$) :

Nous nous plaçons alors exclusivement dans le cas où la population est normale : X suit une **loi normale** de moyenne m et de variance σ^2 .

Nous allons encore distinguer deux cas : celui où σ est connu et celui où σ est inconnu.

σ connu :

Proposition 2

X suit une loi normale $\mathcal{N}(m; \sigma)$ donc les variables X_i suivent toutes la même loi que X . $\forall 1 \leq i \leq n$,

$$X_i \sim \mathcal{N}(m; \sigma) \text{ alors } \bar{X}_n \sim \mathcal{N}(m; \frac{\sigma}{\sqrt{n}}) \text{ donc } Z = \frac{\bar{X}_n - m}{\frac{\sigma}{\sqrt{n}}} \sim \mathcal{N}(0, 1)$$

Exemple 7 Le responsable d'une entreprise a accumulé depuis des années les résultats à un test d'aptitude à effectuer un certain travail. Il semble plausible de supposer que les résultats au test d'aptitude sont distribués suivant une loi normale de moyenne égale 150 et de variance 100. On fait passer le test à 25 individus de l'entreprise. Quelle est la probabilité que la moyenne de l'échantillon soit entre 146 et 154 ?

σ inconnu :

La variance σ^2 est inconnue, il suffit d'utiliser l'estimateur $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$

d'estimation $s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x}_n)^2$

Proposition 3

Dans le cas où σ inconnu, nous allons utiliser la statistique définie par :

$$T = \frac{\bar{X}_n - m}{\frac{S}{\sqrt{n}}} \sim \mathcal{T}_{(n-1)} \text{ la loi de Student de } (n-1) \text{ degrés de liberté .}$$

Exemple 8 Le responsable d'une entreprise a accumulé depuis des années les résultats à un test d'aptitude à effectuer un certain travail. Il semble plausible de supposer que les résultats au test d'aptitude sont distribués suivant une loi normale de moyenne égale 150 et de variance inconnue. On fait passer le test à 25 individus de l'entreprise et la variance mesurée est égale à 10.01 . Quelle est la probabilité que la moyenne de l'échantillon soit entre 151.77 et 152.37 ?

$n \geq 30$ & Population de loi quelconque de moyenne μ et de variance σ^2		
Variance σ^2	$\overline{X}_n$	Ecart réduit
connue	$\overline{X}_n \sim \mathcal{N}(m, \frac{\sigma}{\sqrt{n}})$	$Z = \frac{\overline{X}_n - m}{\frac{\sigma}{\sqrt{n}}} \sim \mathcal{N}(0, 1)$
inconnue, on utilise l'estimation $s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \overline{x}_n)^2$	$\overline{X}_n \sim \mathcal{N}(m, \frac{s}{\sqrt{n}})$	$Z = \frac{\overline{X}_n - m}{\frac{s}{\sqrt{n}}} \sim \mathcal{N}(0, 1)$
$n < 30$ & Population normale de moyenne μ et de variance σ^2		
Variance σ^2	$\overline{X}_n$	Ecart réduit
connue	$\overline{X}_n \sim \mathcal{N}(m, \frac{\sigma}{\sqrt{n}})$	$Z = \frac{\overline{X}_n - m}{\frac{\sigma}{\sqrt{n}}} \sim \mathcal{N}(0, 1)$
inconnue, on utilise l'estimateur $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \overline{X}_n)^2$	$T = \frac{\overline{X}_n - m}{\frac{S}{\sqrt{n}}} \sim T_{n-1}$	$T_{n-1} \sim \text{Student de } (n-1) \text{ ddl}$

3.2 Distribution échantillonnale de la variance S^2 :

Nous nous plaçons alors exclusivement dans le cas où la population est normale : X suit une **loi normale** de moyenne μ et de variance σ^2 . On appelle variance empirique, la statistique notée S^2 , on cherche à caractériser S^2 . Nous allons distinguer deux cas : celui où μ est connue et celui μ est inconnue.

Proposition 4 (μ connue)

Soit $X_1, \dots, X_n$ un échantillon aléatoire d'une variable aléatoire X qui suit une loi normale $\mathcal{N}(m, \sigma)$. Soit la variance échantillonnale S^2 définie par :

$$S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - m)^2 \quad \text{avec} \quad \mathbb{E}(S^2) = \sigma^2$$

$$\Rightarrow Y = \frac{n S^2}{\sigma^2} \sim \chi_n^2 \quad \text{suit une loi de Khi-deux avec } n \text{ degrés de liberté}$$

Proposition 5 (μ inconnue)

Soit $X_1, \dots, X_n$ un échantillon aléatoire d'une variable aléatoire X qui suit une loi normale $\mathcal{N}(\mu, \sigma)$. Soit la variance échantillonnale S^2 définie par :

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2 \quad \text{avec} \quad \mathbb{E}(S^2) = \sigma^2$$

On a,

$$Y = \frac{(n-1) S^2}{\sigma^2} \quad \text{suit une loi du Khi-deux avec } (n-1) \text{ degrés de liberté}$$

Exemple 9 On fait l'hypothèse que la taille (en cm) des 3000 étudiants masculins d'ES-PRIT est une variable aléatoire distribuée normalement de moyenne inconnue et de variance 100. Un échantillon de taille 10 est sélectionné de cette population. Quelle est la probabilité que la variance échantillonnale S^2 soit au plus égale 163.15 ?

Cas possibles	S^2 estimateur de σ^2	Y
m connue	$S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - m)^2$	$Y = \frac{n S^2}{\sigma^2} \sim \chi_n^2$
μ inconnue, on utilise l'estimateur $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$	$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$	$Y = \frac{(n-1) S^2}{\sigma^2} \sim \chi_{n-1}^2$

3.3 Distribution échantillonnale de la proportion $\hat{p}_n$

Soit $X_1, \dots, X_n$ un échantillon aléatoire, telque $X_i \sim \mathcal{B}(p) \forall 1 \leq i \leq n$. Soit $\hat{p}_n$ la fréquence d'apparition du caractère dans un échantillon de taille n , donc

$$\hat{p}_n = \frac{X}{n} = \frac{1}{n} \sum_{i=1}^n X_i$$

où X est le nombre de fois où le caractère apparaît dans le n -échantillon. Par définition X suit $\mathcal{B}(n; p)$.

$$X \sim \mathcal{B}(n; p) \quad \text{avec} \quad E[X] = np \quad \text{et} \quad V[X] = np(1-p)$$

Proposition 6

Soit $X_1, \dots, X_n$ un échantillon aléatoire, tel que $X_i \sim \mathcal{B}(p) \forall 1 \leq i \leq n$, donc

$$\hat{p}_n = \frac{1}{n} \sum_{i=1}^n X_i \quad \text{avec} \quad E[\hat{p}_n] = p \quad \text{et} \quad V[\hat{p}_n] = \frac{p(1-p)}{n}$$

Si $n \geq 30$, $np \geq 5$ et $n(1-p) \geq 5$, alors,

$$\hat{p}_n \sim \mathcal{N}\left(p, \sqrt{\frac{p(1-p)}{n}}\right) \quad \text{et} \quad Z = \frac{\hat{p}_n - p}{\sqrt{\frac{p(1-p)}{n}}} \sim \mathcal{N}(0, 1)$$

Remarque 5

1. L'espérance de la fréquence d'échantillon est égale à la probabilité théorique d'apparition dans la population.
2. Lorsque la taille de l'échantillon augmente, la variance de $\hat{p}_n$ diminue, ce qui est logique : plus on a d'informations, plus il est probable que la proportion observée dans l'échantillon soit proche de la proportion de la population.

Exemple 10 Selon une étude sur le comportement du consommateur, 25% d'entre eux sont influencés par la marque, lors de l'achat d'un bien. Si on interroge 100 consommateurs pris au hasard, quelle est la probabilité pour qu'au moins 35 d'entre eux se déclarent influencés par la marque ?

$n \geq 30 \quad \& \quad np \geq 5 \quad \& \quad nq = n(1-p) \geq 5$	
Loi de $\hat{p}_n$	Ecart réduit
$\hat{p}_n \sim \mathcal{N}\left(p, \sqrt{\frac{p(1-p)}{n}}\right)$	$Z = \frac{\hat{p}_n - p}{\sqrt{\frac{p(1-p)}{n}}} \sim \mathcal{N}(0, 1)$